

Концепция конструктора OCR Pipeline Creator

Настраиваемая обработка документов и извлечение данных с помощью языковых моделей

Назначение системы

Система предназначена для распознавания документов и преобразования их содержимого в текст или набор заданных полей. Пользователь настраивает сценарий обработки в визуальном конструкторе, сохраняет его как пайплайн и применяет к новым файлам. Результаты доступны в общей истории рабочего пространства и через API для внешних систем.

Основной принцип

В системе разделяются получение текста и его дальнейшая обработка. Текст извлекается из цифрового документа либо распознается по скану. Затем языковая модель выполняет инструкцию или заполняет заданные поля. Каждый этап настраивается отдельно; если обработка моделью отключена, результатом остается полученный текст.

Этап	Содержимое	Назначение
Получение текста	Чтение цифрового файла или OCR скана	Подготовка текста для дальнейшей обработки
Обработка текста	Инструкция, модель и схема извлекаемых полей	Свободный текст или структурированный JSON

Структура пайплайна

Пайплайн объединяет настройки для повторяемой обработки документов:

- Сохраненный сценарий обработки
 - Уникальный идентификатор и название
 - Тип источника — цифровой документ или скан
 - Способ OCR — vision-модель или внешний сервис
 - Модель извлечения и параметры генерации
 - Инструкция для обработки текста
 - Имена и описания извлекаемых полей
 - Переключатели OCR, инструкции и извлечения полей

Конструктор состоит из трех этапов: название, источник и обработка. Инструкция и поля включаются независимо; при совместном включении инструкция уточняет правила извлечения.

Пайплайн хранится в PostgreSQL, имеет постоянный ID и используется как в интерфейсе, так и при запуске через API.

Подготовка и настройка обработки

1. Администратор задает название и уникальный ID пайплайна, по которому внешние системы смогут запускать обработку.
2. Выбирается тип источника. PDF с текстовым слоем, DOCX и текстовые файлы читаются напрямую; для сканов и изображений настраивается OCR.
3. Для распознавания указывается vision-модель через LiteLLM либо адрес OCR-сервиса с необходимыми параметрами.
4. Для дальнейшей обработки выбирается модель, задается инструкция и при необходимости список полей с описаниями.
5. Настройки сохраняются. Качество сценария следует проверять на характерных документах перед подключением к рабочему процессу.

Обработка пользовательского документа

1. Пользователь выбирает сохраненный пайплайн и загружает файл. Внешняя система передает файл и ID пайплайна через API.
2. При фоновом запуске исходник сохраняется в S3, а задача и событие ее отправки — в PostgreSQL. Диспетчер передает задачу в очередь Redis.
3. Воркер получает файл и извлекает текст напрямую либо выполняет OCR. При включенной обработке текст передается выбранной модели.
4. Для режима полей проверяются формат JSON, состав ключей и типы значений. Некорректный ответ завершает задачу с ошибкой.
5. Успешный результат сохраняется в истории. Пользователь просматривает исходник, текст и поля; интеграция получает результат через API.

Режимы обработки и интеграция

Интерфейс запускает обработку в фоне с отображением состояния задачи. API поддерживает синхронный ответ и фоновый запуск с идентификатором для проверки статуса. Для каждой интеграции создается отдельный API-ключ с доступом к выбранным пайплайнам. Ключ позволяет получать только собственные задачи и документы.

Хранение и проверка результатов

Исходные файлы хранятся в приватном S3-хранилище, а настройки, задачи, распознанный текст и результаты — в PostgreSQL. В истории можно открыть или скачать исходник и исправить извлеченные поля. Правки не изменяют исходный файл и первоначальный ответ модели. Контроль ревизии предотвращает перезапись конфликтующих изменений.

- Исходник — загруженный документ для последующей проверки
- Текст — содержимое после чтения файла или OCR
- Результат — исходный ответ модели в виде текста или JSON
- Поля — текущие значения с учетом правок пользователя
- Задача — состояние обработки, число попыток и сведения об ошибке

Правила надежности

- Сохранение исходника. Результат можно сверить с загруженным документом.
- Строгая схема. В режиме полей допускаются только заданные ключи и значения в виде строк или null.
- Явная ошибка. Отказ модели или неверный JSON не сохраняется как успешный документ.
- Контроль повторов. Временные сбои обрабатываются повторными попытками в пределах лимитов.
- Защита результата. Устаревшие запуски задачи не могут перезаписать итог обработки.
- Разграничение доступа. Администратор управляет настройками, пользователь работает с документами, API-ключ ограничен своей интеграцией.

Оценка качества

Метрика	Что измеряет
Ошибки распознавания	Доля ошибок в символах и словах относительно эталонного текста
Точность значений полей	Доля полей, значения которых совпадают с эталоном
Полнота извлечения	Доля присутствующих в документе целевых значений, которые удалось извлечь
Соответствие схеме	Доля ответов модели, прошедших проверку JSON и типов значений
Время обработки	Полное время от приема файла до результата, включая ожидание в очереди
Доля ручных исправлений	Доля извлеченных полей, исправленных пользователем после обработки

Ожидаемый результат

Проект объединяет распознавание, извлечение данных и проверку результатов в настраиваемый процесс. Ожидаемый эффект — сокращение ручного переноса сведений и времени подключения новых типов документов. Пайплайны позволяют повторно использовать настройки, а API — включать обработку в другие системы. Качество зависит от исходных файлов и выбранных моделей; его следует оценивать на эталонной выборке с проверкой результатов человеком.