

Концепция ИИ ассистента по нормативным правовым актам

Иерархическая навигация по документам с ответами на основе исходных фрагментов

Назначение системы

Система предназначена для поиска требований в локальных и федеральных нормативных документах и подготовки ответов с точными ссылками на первоисточник. Корпус хранится как структурированная иерархия, а языковая модель использует описания уровней только для выбора направления поиска. Достоверные факты извлекаются исключительно из исходных чанков документа.

Основной принцип

В системе разделяются навигационный и доказательный слои. Метаданные и краткие описания отвечают на вопрос, где искать. Исходные чанки отвечают на вопрос, что именно установлено документом. Агент обязан дойти до чанков перед формированием ответа.

Слой	Содержимое	Использование
Навигационный	Описания категорий, документов, разделов и чанков	Маршрутизация, отбор веток и ранжирование кандидатов
Доказательный	Оригинальный текст абзацев, таблиц, списков и рисунков	Извлечение фактов, цитирование и формирование ответа

Структура корпуса

Документы организуются по естественной структуре нормативной базы:

- Корень корпуса
 - Локальные документы
 - Федеральные документы
 - Категория документов при необходимости
 - Документ
 - Раздел, глава, статья или приложение
 - Чанк
 - Сабчанк для фрагментов, превышающих допустимый размер контекста

Чанком считается самостоятельный элемент документа: абзац, список, таблица, рисунок или иной содержательный блок. Каждый узел хранит идентификатор, тип, заголовок, ссылку на родителя, порядок в документе и навигационное описание. Для документа и его частей дополнительно фиксируются версия и период действия, если эти сведения доступны.

Подготовка и индексация документов

1. Парсер определяет структуру каждого документа и выделяет его элементы без потери их порядка и принадлежности к разделам.
2. Крупные элементы разбиваются на сабчанки, при этом сохраняется связь с исходным чанком и общим контекстом.
3. Для каждого чанка языковая модель формирует краткое навигационное описание без замены исходного текста.
4. Описания верхних уровней строятся снизу вверх: раздел по описаниям чанков, документ по описаниям разделов, категория по описаниям документов.
5. Исходный текст и сгенерированные описания хранятся раздельно. Описания маркируются как недостоверные для цитирования навигационные данные.

Обработка пользовательского запроса

1. Система анализирует запрос и при необходимости разбивает его на отдельные вопросы.
2. По описаниям верхнего уровня выбираются несколько релевантных категорий и документов. Выбор одной ветки не допускается, чтобы ранняя ошибка не исключила правильный источник.
3. По каждой выбранной ветке агент переходит к разделам и затем к исходным чанкам.
4. Формируется набор доказательств из релевантных чанков. Дополнительно проверяются соседние фрагменты, исключения, определения и ссылки на другие нормы.
5. Ответ создается только по содержимому набора доказательств и сопровождается ссылками на документ, раздел, статью, пункт или иной доступный адрес фрагмента.

Гибридный поиск

Иерархическая навигация работает совместно с глобальным поиском по всему корпусу. Параллельно выполняются полнотекстовый и векторный поиск по исходным чанкам и их контекстным представлениям. Результаты объединяются и передаются ранжирующей модели. Такой резервный канал снижает риск пропуска нормы из-за неточного описания или ошибки маршрутизации.

Связи и версии документов

Основная структура корпуса является деревом, но нормативные документы также образуют граф связей. Для узлов фиксируются ссылки на другие положения, изменения, отмена, замещение и конкретизация. При ответе система должна учитывать актуальность редакции и переходить по релевантным связям, если вопрос затрагивает взаимозависимые нормы.

- REFERENCES — ссылка на другую норму
- AMENDS — внесение изменений
- SUPERSEDES — замещение или отмена
- IMPLEMENTS — конкретизация или реализация требований
- RELATED TO — иная значимая связь

Правила надежности

- Ответ по первоисточнику. Описания не являются основанием для утверждений или цитат.
- Обязательный спуск до чанка. Остановка на уровне документа или раздела запрещена.
- Проверка контекста. Учитываются соседние чанки, определения, исключения и связи.
- Несколько веток. На каждом уровне сохраняются несколько релевантных вариантов.
- Отказ без доказательств. При отсутствии исходных фрагментов система не достраивает ответ.
- Точная трассировка. Утверждение связывается с конкретным фрагментом и версией документа.

Оценка качества

Метрика	Что измеряет
Document Routing Accuracy	Доля запросов, для которых нужный документ сохранился среди кандидатных веток
Section Routing Accuracy	Доля запросов, для которых найден правильный раздел
Recall at k	Полнота извлечения эталонных доказательных чанков
Precision at k	Доля действительно релевантных чанков в выдаче
Citation Accuracy	Корректность связи утверждений ответа с указанными источниками
Answer Faithfulness	Соответствие ответа содержанию найденных исходных фрагментов

Ожидаемый результат

Предлагаемый подход представляет собой иерархический RAG, использующий естественную структуру НПА как основную карту поиска. Ожидаемое преимущество перед плоским поиском — более точный выбор документа и раздела для сложных вопросов, распределенных по нескольким источникам. Итоговая достоверность обеспечивается не описаниями дерева, а обязательным переходом к оригинальным чанкам и формированием проверяемого набора доказательств.